共轭梯度法与 Krylov 子空间：从构造到最优性

> **核心结论**：CG 不是先假设正交性，再猜出递推式。它先用精确线搜索和完整的 A-正交化构造共轭方向法，证明残差两两正交后，才把完整正交化化简成短递推。得到的迭代点，是逐渐扩大的 Krylov 仿射空间中的能量范数最优近似。

本文按原讲解的逻辑整理，保留 $A=\begin{pmatrix}4&1\\1&3\end{pmatrix}$ 的数值例子，并扩充 Krylov 空间、Galerkin 条件、多项式与谱的联系。讨论对象是实对称正定线性系统；除特别说明外，理论证明采用精确算术，且在当前残差非零时继续迭代。

1. 从线性方程组到二次优化

考虑

$$Au=b,\qquad A\in\mathbb{R}^{n\times n},\quad A^T=A,\quad v^TAv>0\ (v\neq 0).$$

构造严格凸二次函数

$$J(u)=\tfrac{1}{2}u^TAu-b^Tu,\qquad \nabla J(u)=Au-b,\quad \nabla^2J=A\succ 0.$$

唯一极小点 u_* 满足 $Au_*=b$。定义残差和误差为

$$r_k=b-Au_k=-\nabla J(u_k),\qquad e_k=u_*-u_k,\qquad r_k=Ae_k.$$

残差可由当前迭代点计算；误差需要未知的精确解，实际程序通常无法直接获得。残差是负梯度，但一般不等于误差。

符号	含义
u_k	第 k 个近似解
r_k	残差，也是当前负梯度
p_k	搜索方向，通常不是当前负梯度本身
α_k	沿 p_k 的精确线搜索步长
β_k	短递推中的方向修正系数
$\langle x,y\rangle_A=x^TAy$	由 SPD 矩阵定义的内积

2. 第一步：精确线搜索自然带来正交性

从任意 u_0 开始，取 $p_0=r_0$。若 $r_0=0$，已得到解；否则沿方向最小化：

$$\alpha_0=\operatorname*{argmin}_{\alpha\in\mathbb{R}}J(u_0+\alpha p_0).$$

展开后

$$J(u_0+\alpha p_0)=J(u_0)-\alpha p_0^T r_0+\tfrac{1}{2}\alpha^2 p_0^T A p_0.$$

令关于 α 的导数为零：

$$\alpha_0=\frac{p_0^T r_0}{p_0^T A p_0}=\frac{r_0^T r_0}{p_0^T A p_0}.$$

更新

$$u_1=u_0+\alpha_0 p_0,\qquad r_1=r_0-\alpha_0 A p_0.$$

于是

$$r_1^T p_0=r_0^T p_0-\alpha_0 p_0^T A p_0=0.$$

因为 $p_0=r_0$，也得到 $r_1^T r_0=0$。

> **核心结论**：新残差与刚走过的方向正交，是精确线搜索的结果。第一步得到 $r_1\perp r_0$，不等于已经证明了所有残差两两正交。

3. 共轭条件从哪里来?

若每次都取 $p_k=r_k$，就是最速下降法。下一次沿新梯度走时，可能破坏以前已经取得的方向最优性，导致反复修正。

我们希望更新后仍保留沿 p_0 的最优性。先提出可调整的候选方向

$$p_1=r_1+c_0 p_0.$$

若下一步为 $u_2=u_1+\alpha_1 p_1$，则

$$r_2^T p_0=r_1^T p_0-\alpha_1 p_1^T A p_0.$$

已有 $r_1^T p_0=0$。为使新更新不破坏它，我们主动要求

$$p_1^T A p_0=0.$$

代入候选式解出

$$c_0=-\frac{r_1^T A p_0}{p_0^T A p_0},\qquad p_1=r_1-\frac{r_1^T A p_0}{p_0^T A p_0}p_0.$$

这里 A-共轭性首先是**设计要求**；由选择系数保证之后，才成为可用于后续证明的已知事实。

普通正交与共轭是不同的：

$$x^T y=0\quad\text{是普通正交},\qquad x^T A y=0\quad\text{是 }A\text{-正交}.$$

几何上，$x^T A y=(A^{1/2}x)^T(A^{1/2}y)$。共轭方向是在变换后的坐标里垂直，在原坐标中未必呈直角。

4. 完整的 A–Gram–Schmidt 构造

在第 k 步，从新负梯度出发，允许使用全部旧方向：

$$p_k = r_k + \sum_{j=0}^{k-1} c_j p_j.$$

假设旧方向已按相同程序构造，因而彼此 A-共轭。要求 $p_k^T A p_j = 0$，得到

$$c_j = -\frac{r_k^T A p_j}{p_j^T A p_j},$$

即

$$\boxed{p_k = r_k - \sum_{j=0}^{k-1} \frac{r_k^T A p_j}{p_j^T A p_j} p_j.}$$

这是在 A-内积下对 r_k 做 Gram – Schmidt。现在它还是一个需要保存所有旧方向的算法，并未得到 CG 的短递推。

算法构造与证明要按以下顺序理解：

```
完整 A–正交化：保证新旧方向共轭
            ↓
精确线搜索：证明新残差与全部已用方向正交
            ↓
残差属于已有方向的张成空间：推出残差两两正交
            ↓
较早的投影系数变为零：完整构造化简为短递推
```

5. 严格证明残差的 mutual orthogonality

5.1 先证明残差与所有旧方向正交

归纳假设在第 k 步开始时

$$r_k^T p_j = 0 \qquad (j < k).$$

基础情形 $k = 0$ 没有旧方向；$k = 1$ 的结论已由第一次线搜索得到。完整正交化保证 $p_k^T A p_j = 0$，并且

$$r_k^T p_k = r_k^T r_k + \sum_{j<k} c_j r_k^T p_j = r_k^T r_k.$$

因此精确线搜索给出

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}, \qquad r_{k+1} = r_k - \alpha_k A p_k.$$

对当前方向，

$$r_{k+1}^T p_k = r_k^T r_k - \alpha_k p_k^T A p_k = 0.$$

对任意 $j < k$，

$$r_{k+1}^T p_j = \underbrace{r_k^T p_j}_{0} - \alpha_k \underbrace{p_k^T A p_j}_{0} = 0.$$

归纳完成：

$$\boxed{r_{k+1}^T p_j = 0 \quad (0 \le j \le k).}$$

这也说明 $r_k \neq 0$ 时 $p_k \neq 0$：否则 $r_k^T p_k = r_k^T r_k > 0$ 不可能成立。故 SPD 保证继续迭代时的分母 $p_k^T A p_k$ 为正。

5.2 再推出残差两两正交

由方向构造式，

$$r_j = p_j - \sum_{i<j} c_i p_i \in \operatorname{span}\{p_0, \dots, p_j\}.$$

而 r_{k+1} 与 $p_0, \dots, p_k$ 全部正交，所以

$$r_{k+1}^T r_j = 0 \quad (j \le k).$$

因此

$$\boxed{r_i^T r_j = 0 \quad (i \neq j).}$$

逻辑关键：残差两两正交是“完整共轭方向构造 + 精确线搜索”的推论，没有作为前提偷偷放进步长或方向推导中。

6. 为什么只需保留上一个方向?

对下一步完整正交化：

$$p_{k+1} = r_{k+1} - \sum_{j=0}^{k} \frac{r_{k+1}^T A p_j}{p_j^T A p_j} p_j.$$

由残差更新可写

$$A p_j = \frac{r_j - r_{j+1}}{\alpha_j}.$$

当 $j < k$ 时，$j, j+1 \le k$，已经证明的残差正交性给出

$$r_{k+1}^T A p_j = \frac{r_{k+1}^T r_j - r_{k+1}^T r_{j+1}}{\alpha_j} = 0.$$

因此只有最后一项保留下来：

$$p_{k+1} = r_{k+1} + \beta_k p_k, \qquad \beta_k = -\frac{r_{k+1}^T A p_k}{p_k^T A p_k}.$$

再利用

$$r_{k+1}^T A p_k = -\frac{r_{k+1}^T r_{k+1}}{\alpha_k}, \qquad \alpha_k p_k^T A p_k = r_k^T r_k,$$

得到

$$\boxed{\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}.}$$

> **核心结论**：CG 的“两项方向递推”不是随意猜出来的形式，而是完整正交化在 SPD 二次问题和精确线搜索下的精确化简。若新残差为零，应停止，不必再构造下一个方向。

7. 完整算法与停止准则

```
输入：SPD 算子 A、右端 b、初值 u、容差 atol/rtol、迭代上限
r = b − A∗u
p = r
rho = dot(r,r)
tol = max(atol, rtol∗norm(b))
若 norm(r) <= tol：返回 u

for k = 0, ..., maxiter−1:
    q = A∗p
    d = dot(p,q)
    若 d 非正或出现非有限数：报告 SPD/数值异常
    alpha = rho/d
    u = u + alpha∗p
    r = r − alpha∗q
    rho_new = dot(r,r)
    若 sqrt(rho_new) <= tol：
        r_true = b−A∗u
        若 norm(r_true) <= tol：返回 u
        r = r_true
        p = r
        rho = dot(r,r)
        continue（以真实残差重启）
    beta = rho_new/rho
    p = r + beta∗p
    rho = rho_new

返回 u，并报告“达到上限”及真实残差
```

核心迭代每步一次矩阵向量乘法和若干内积、向量更新；不计停止验证时额外的真实残差计算。除了矩阵或算子，只需保存少量长度为 n 的向量。稀疏矩阵乘法成本约为 $O(\mathrm{nnz}(A))$，不是显式形成 A^k。

同时给出绝对和相对容差，可处理 $b = 0$ 时不能除以 $\|b\|$ 的情况。程序中的递推残差与真实残差会因舍入误差产生差距，详见第 13 节。

8. 原数值例子：两步得到精确解

取

$$A=\begin{pmatrix}4 & 1\\ 1 & 3\end{pmatrix},\quad b=\begin{pmatrix}1\\ 2\end{pmatrix},\quad u_0=\begin{pmatrix}0\\ 0\end{pmatrix}.$$

A 对称，且顺序主子式为 $4>0$、$\det A=11>0$，所以它是 SPD。

8.1 第一次迭代

$$r_0=p_0=\begin{pmatrix}1\\ 2\end{pmatrix},\qquad Ap_0=\begin{pmatrix}6\\ 7\end{pmatrix}.$$

$$\alpha_0=\frac{5}{20}=\frac{1}{4},\quad u_1=\begin{pmatrix}1/4\\ 1/2\end{pmatrix},\quad r_1=\begin{pmatrix}-1/2\\ 1/4\end{pmatrix}.$$

检查 $r_1^Tr_0=-1/2+1/2=0$。因为 $r_1^Tr_1=5/16$，

$$\beta_0=\frac{5/16}{5}=\frac{1}{16},\qquad p_1=r_1+\tfrac{1}{16}p_0=\begin{pmatrix}-7/16\\ 3/8\end{pmatrix}.$$

$$Ap_1=\begin{pmatrix}-11/8\\ 11/16\end{pmatrix},\qquad p_0^TAp_1=0.$$

注意 $p_0^Tp_1=5/16\neq 0$：这两个方向共轭，但并不普通正交。

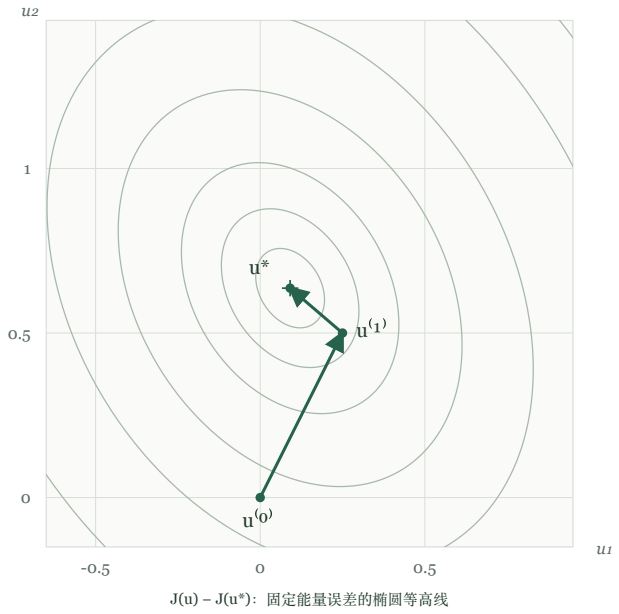
8.2 第二次迭代

$$p_1^TAp_1=\frac{55}{64},\qquad \alpha_1=\frac{5/16}{55/64}=\frac{4}{11}.$$

$$u_2=u_1+\alpha_1p_1=\begin{pmatrix}1/11\\ 7/11\end{pmatrix},\qquad Au_2=b,\qquad r_2=0.$$

迭代点	u_k	r_k	$\|r_k\|_2$
$k=0$	$(0,0)^T$	$(1,2)^T$	$\sqrt{5}$
$k=1$	$(1/4,1/2)^T$	$(-1/2,1/4)^T$	$\sqrt{5}/4$
$k=2$	$(1/11,7/11)^T$	$(0,0)^T$	0

以上分数均按精确有理数复算。对应目标值为 $J(u_0)=0$、$J(u_1)=-5/8$、$J(u_*)=-15/22$。



原例子中的目标等高线与完整 CG 轨迹；两个坐标分量采用同一尺度。

图中每条椭圆代表固定的目标差 $J(u)-J(u_*)$；坐标轴采用相同尺度。两段路径对应两次精确线搜索，不表示搜索方向在原坐标中互相垂直。网页版本可以逐步切换 $k=0,1,2$。

9. Krylov 子空间：从一个向量逐层扩展

9.1 定义与最直接的直觉

$$\mathcal{K}_m(A,r_0)=\operatorname{span}\{r_0,Ar_0,\dots,A^{m-1}r_0\},\qquad \mathcal{K}_0=\{0\}.$$

span 表示所有线性组合。因此

$$\begin{aligned}\mathcal{K}_1&=\{a_0r_0\},\\ \mathcal{K}_2&=\{a_0r_0+a_1Ar_0\},\\ \mathcal{K}_3&=\{a_0r_0+a_1Ar_0+a_2A^2r_0\}.\end{aligned}$$

第一层只能调整初始残差的倍数；第二层额外利用 A 作用一次带来的信息；随后继续加入矩阵作用产生的新方向。

$$\mathcal{K}_0\subseteq\mathcal{K}_1\subseteq\mathcal{K}_2\subseteq\cdots,\qquad \dim\mathcal{K}_m\le m.$$

包含关系不一定严格，维数也不一定每步增加。例如若 $Ar_0=\lambda r_0$，后面的所有幂都与 r_0 平行，空间始终只有一维；CG 此时一步就能消除该特征方向的误差。

> **核心结论**：Krylov 空间由 (A,r_0) 共同决定。它不是“矩阵的前几列”，也不是自动与坐标轴对齐的空间；改变初值会改变 r_0，因而可能改变整个搜索空间。

9.2 在原例子里亲手算一层

$$r_0=\begin{pmatrix}1\\2\end{pmatrix},\quad Ar_0=\begin{pmatrix}6\\7\end{pmatrix},\quad \det\begin{pmatrix}1&6\\2&7\end{pmatrix}=-5\neq0.$$

所以 $\mathcal{K}_1$ 是一条直线，$\mathcal{K}_2 = \mathbb{R}^2$。第一次迭代在线 $u_0 + \mathcal{K}_1$ 上最优；第二次已经能在整个平面寻找最优解。

同一个空间可以有不同基。本例

$$p_1 = \frac{17}{16} r_0 - \frac{1}{4} A r_0,$$

因此 $\{p_0, p_1\}$ 和 $\{r_0, Ar_0\}$ 张成同一个二维空间，但前者还具有 A-共轭结构。

9.3 为什么 CG 的方向就在这个空间里?

从 $p_0 = r_0 \in \mathcal{K}_1$ 开始，递推式依次给出

$$Ap_k \in \mathcal{K}_{k+2}, \quad r_{k+1} = r_k - \alpha_k A p_k \in \mathcal{K}_{k+2}, \quad p_{k+1} \in \mathcal{K}_{k+2}.$$

归纳得到 $p_k, r_k \in \mathcal{K}_{k+1}$。每次更新是旧方向的线性组合，所以

$$u_k - u_0 \in \operatorname{span}\{p_0, \dots, p_{k-1}\} \subseteq \mathcal{K}_k.$$

非零共轭方向线性无关：若 $\sum_j c_j p_j = 0$，左乘 $p_i^T A$，便得 $c_i p_i^T A p_i = 0$，从而 $c_i = 0$。

只要尚未提前终止，左边张成空间的维数是 k；而右边 $\dim \mathcal{K}_k \le k$，因此

$$\boxed{\mathcal{K}_k(A, r_0) = \operatorname{span}\{p_0, \dots, p_{k-1}\}.}$$

这是包含关系加维数论证，不是把“CG 必须使用 Krylov 基”当成先验假设。

9.4 为什么不直接存 $r_0, Ar_0, A^2 r_0, \dots$?

原始幂向量可能迅速变得近似线性相关：反复乘 A 会放大某些特征方向，导致基底数值病态。CG 在精确算术中以同一空间的共轭基工作，并利用短递推避免保存全部历史。

算法只需要计算 Ap_k。定义里出现 A^{m-1}，不等于程序必须显式计算或存储矩阵幂。

10. Galerkin 条件与能量范数最优性

10.1 仿射搜索空间上的一阶条件

前面已证明 $r_k \perp p_j$（$j < k$），结合空间相等关系，得到

$$u_k \in u_0 + \mathcal{K}_k, \qquad r_k \perp \mathcal{K}_k.$$

第二个条件就是这里的 Galerkin 正交条件。对任意 $v \in \mathcal{K}_k$，

$$\frac{d}{dt} J(u_k + tv)\Big|_{t=0} = -v^T r_k = 0.$$

严格凸性保证这一驻点是整个仿射空间里的唯一极小点：

$$\boxed{u_k = \operatorname*{argmin}_{u \in u_0 + \mathcal{K}_k} J(u).}$$

虽然实际每次只沿一条新直线做搜索，共轭性保证已完成的方向最优性不被破坏，所以最终等价于在整个当前子空间中重新优化。

10.2 能量范数与投影

由 $Au_* = b$，展开可得

$$J(u) - J(u_*) = \tfrac{1}{2}(u-u_*)^T A(u-u_*) = \tfrac{1}{2}\|u-u_*\|_A^2,$$

其中 $\|v\|_A = \sqrt{v^T A v}$。因此

$$\boxed{\|e_k\|_A = \min_{u \in u_0 + \mathcal{K}_k} \|u_* - u\|_A.}$$

又因为 $r_k = Ae_k$，$r_k \perp \mathcal{K}_k$ 等价于 e_k 与 $\mathcal{K}_k$ 在 A-内积下正交。CG 可以理解为相对于能量内积的最佳投影。

不要偷换范数：这不意味着 CG 每步最小化 $\|b - Au\|_2$。CG 最优的是 A-范数误差，等价于 A^{-1}-范数残差：

$$\|r_k\|_{A^{-1}}^2 = r_k^T A^{-1} r_k = e_k^T A e_k.$$

因此 $J(u_k)$ 和 $\|e_k\|_A$ 在精确算术中单调不增，但欧氏残差范数 $\|r_k\|_2$ 不保证单调不增。

11. 多项式、谱与有限步收敛

11.1 Krylov 修正就是矩阵多项式

任何 $u \in u_0 + \mathcal{K}_k$ 都可写成

$$u = u_0 + s_{k-1}(A) r_0, \qquad \deg s_{k-1} \le k-1.$$

由于 $r_0 = Ae_0$，误差为

$$e = \big[I - A s_{k-1}(A)\big] e_0 = \pi_k(A) e_0,$$

其中 $\deg \pi_k \le k$、$\pi_k(0) = 1$。反过来，每个满足这两个条件的多项式，都可通过 $s(t) = [1-\pi(t)]/t$ 对应一个 Krylov 修正。

所以 CG 的最优性还可以写成

$$\|e_k\|_A = \min_{\deg \pi \le k,\, \pi(0)=1} \|\pi(A) e_0\|_A.$$

这里的“选择多项式”是对迭代效果的解释，不是算法显式枚举多项式。

11.2 从特征分量看迭代在做什么

令 $Av_i = \lambda_i v_i$，特征向量为正交单位基，$e_0 = \sum_i \gamma_i v_i$。则

$$e_k = \sum_i \gamma_i \pi_k(\lambda_i) v_i, \qquad \|e_k\|_A^2 = \sum_i \lambda_i \gamma_i^2 \pi_k(\lambda_i)^2.$$

因此，CG 可以看作寻找一个在相关特征值上足够小的低次多项式，以削弱误差的特征分量。初始误差本来没有的分量（$\gamma_i = 0$）不需要消除。

11.3 至多 n 步，以及更精细的结论

在 $\mathbb{R}^n$ 中，最多有 n 个非零、线性无关的共轭方向。如果此前未收敛，$p_0, \dots, p_{n-1}$ 张成整个空间，而 r_n 与它们全正交，故只能是 $r_n = 0$。

多项式观点给出更强结论。假设初始误差涉及的不同特征值只有 $\theta_1, \dots, \theta_s$，则

$$\pi(t) = \prod_{j=1}^{s} \left(1 - \frac{t}{\theta_j}\right)$$

满足 $\pi(0) = 1$，且消除全部相关特征分量。因此 CG 在精确算术下至多 $s \le n$ 步收敛。这个 s 也是相对 r_0 的最小多项式次数（$r_0 \neq 0$ 时）。

这说明“大矩阵也可能很快收敛”；关键不只在矩阵阶数，还在谱结构和初始误差。若 $r_0 = 0$，则第零步已经完成。

11.4 条件数界与特征值聚集

设 $\kappa_2(A) = \lambda_{\max}/\lambda_{\min}$。对 $\kappa_2(A) > 1$，经典最坏情形界为

$$\frac{\|e_k\|_A}{\|e_0\|_A} \le 2 \left(\frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1} \right)^k.$$

其来源是用在整个谱区间上较小的 Chebyshev 多项式界定最优多项式的效果。$\kappa = 1$ 时 A 是正标量乘单位阵，非零初始误差一步就可消除。

这个界不是精确的迭代次数预测。真实特征值如果集中成若干簇，低次多项式可能在这些位置已经很小，实际收敛会比只看端点的条件数界更好。该界控制的是能量误差，也不是欧氏残差每步下降的保证。

12. 与 Lanczos、预条件和其他方法的联系

12.1 为什么对称矩阵允许短递推?

Lanczos 用欧氏正交基表示同一个 Krylov 空间。若 V_k 的列是相应基向量，则

$$V_k^T A V_k = T_k,$$

T_k 为对称三对角矩阵。投影解 $u_k = u_0 + V_k y_k$ 满足

$$T_k y_k = V_k^T r_0 = \|r_0\|_2 \, e_1.$$

CG 与 Lanczos 投影解法在精确算术下紧密对应，但使用的方向基不同。对称性带来的三对角结构解释了为什么只需短的历史信息；本篇第 6 节则直接从残差正交性推导了 CG 的具体短递推。

12.2 预条件改变的是哪个问题?

若 M 为 SPD 预条件矩阵，可考察对称变换

$$\widetilde{A} = M^{-1/2} A M^{-1/2}, \quad \widetilde{b} = M^{-1/2} b, \quad y = M^{1/2} u.$$

对 $\widetilde{A} y = \widetilde{b}$ 使用 CG，等价于适当形式的 PCG；实现通常求解 $Mz = r$，无需显式形成平方根或逆矩阵。目标是改善变换后算子的谱与条件数。

不能直接照搬普通 CG 的全部正交式：PCG 的原始残差一般不再满足普通欧氏两两正交；对应关系应在变换坐标或相关加权内积下表述。也不能因为 $M^{-1}A$ 看起来是“预条件后的矩阵”，就把它当作欧氏内积下对称的矩阵处理。

12.3 方法选择的边界

CG 面向 SPD 线性系统。非对称系统和对称不定系统需要不同的理论与方法；非线性 CG 也不是把这里的有限步和精确正交结论原样搬过去。GMRES 在 Krylov 空间中最小化的是欧氏残差范数，与 CG 的能量误差最优性应区分。

13. 浮点计算：哪些结论需要重新解释?

实际计算会逐步丢失精确的残差正交性与方向共轭性。因此“至多 n 步”是精确算术定理，不是浮点程序的硬性承诺；微小的非零内积也不自动说明算法写错。

递推残差由 $r \leftarrow r - \alpha Ap$ 得到，而真实残差是直接计算的 $b - Au$。两者可能出现 residual gap。可以在预定时机重算真实残差，或在准备宣布收敛时验证它；若采用残差替换与重启，应使用一致的更新策略，不能任意替换一个向量后假定所有精确递推关系仍成立。

一个常用的混合判据是

$$\|b - Au_k\|_2 \le \max\{\mathrm{atol},\ \mathrm{rtol}\|b\|_2\}.$$

当需要解释误差时，注意

$$\frac{\|r_k\|_2}{\lambda_{\max}} \le \|e_k\|_2 \le \frac{\|r_k\|_2}{\lambda_{\min}}.$$

对于 $b \neq 0$，还可用 $\|e_k\|_2/\|u_*\|_2 \le \kappa_2(A)\|r_k\|_2/\|b\|_2$ 作一般上界。病态系统中，小相对残差不一定意味着同样小的相对解误差。

14. 整体逻辑：构造、定理、简化

```
Au=b，A 对称正定
  ↓ 等价于最小化严格凸二次函数 J
精确线搜索 + 完整 A-Gram–Schmidt
  ↓ 共轭性由构造保证；残差与已用方向正交
残差两两正交
  ↓ 较早的正交化系数为零
CG 短递推：alpha、更新 u/r、beta、更新 p
  ↓ 方向张成 Krylov 空间
Galerkin 条件与能量范数最优性
  ↓ 多项式消除相关特征分量
精确算术下有限步收敛；浮点中验证真实残差
```

复习时可依次问：**设计什么条件？已经证明了什么？哪些式子只是利用定理后的简化？** 这三个层次分清后，就不必把算法当成一组来历不明的公式。

15. 常见误区与自测

容易误解的说法	正确理解
先假设 $r_i^T r_j = 0$ 再推步长	先用完整构造与精确线搜索证明，再化简
共轭方向一定在图上垂直	垂直关系在 A-内积下成立
每次线搜索只做到当前方向最优	共轭性保留旧方向最优性，因此也是当前整个空间最优
$r_k \perp \mathcal{K}_{k+1}$	一般是 $r_k \perp \mathcal{K}_k$；r_k 自身属于 $\mathcal{K}_{k+1}$
$\dim \mathcal{K}_k = k$ 永远成立	只在相应独立、未提前终止阶段成立，之后可不再增长
Krylov 方法要计算矩阵幂	只需矩阵向量乘法来隐式产生空间
CG 最小化欧氏残差	CG 最小化能量误差，等价于加权残差
$\|r_k\|_2$ 必须单调下降	能量误差单调不增，欧氏残差不保证
浮点程序必须在 n 步内结束	有限步结论依赖精确算术
预条件后所有正交关系不变	要在相应变换坐标或加权内积下重新表述

自测：不翻算法，能否说明 $p_k \neq 0$ 的理由？能否用两行等式证明 $r_{k+1}^T A p_j = 0$（$j < k$）？能否解释为什么一条条线搜索等价于空间最优化？能否说出“一步收敛”的谱条件？

参考与进一步阅读

正文以提供的最后一次 CG 讲解为主，保留其构造顺序和原数值例子；Krylov 的多项式、谱、Lanczos 与预条件联系为扩展内容。

- Shewchuk：An Introduction to the Conjugate Gradient Method Without the Agonizing Pain：适合继续阅读共轭方向、几何直觉与多项式分析。
- Netlib：Templates for the Solution of Linear Systems：可进一步查阅 CG、预条件和迭代停止相关的算法说明。

16. 一页式复习摘要

问题与记号

$$Au = b,\ A = A^T \succ 0; \qquad J(u) = \tfrac{1}{2}u^T Au - b^T u, \quad r_k = b - Au_k = Ae_k.$$

构造顺序

完整 A-正交化 + 精确线搜索 → 残差与旧方向正交 → 残差两两正交 → 完整正交化化简成短递推。 共轭性是设计条件，残差正交是推论，短递推是进一步的结果。

CG 五式

$$\begin{aligned} \alpha_k &= \frac{r_k^T r_k}{p_k^T A p_k}, & u_{k+1} &= u_k + \alpha_k p_k, \\ r_{k+1} &= r_k - \alpha_k A p_k, & \beta_k &= \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}, \\ p_{k+1} &= r_{k+1} + \beta_k p_k. \end{aligned}$$

初始化 $r_0 = b - Au_0$、$p_0 = r_0$；残差为零时停止。核心每步一次 Ap_k，外加少量向量操作。

正交、空间与最优性

$$p_i^T A p_j = 0\ (i \neq j), \quad r_i^T r_j = 0\ (i \neq j), \quad r_k \perp \mathcal{K}_k.$$

$$\mathcal{K}_k = \operatorname{span}\{r_0, Ar_0, \ldots, A^{k-1}r_0\}, \quad u_k = \operatorname*{argmin}_{u \in u_0 + \mathcal{K}_k} \|u_* - u\|_A.$$

误差可写为 $e_k = \pi_k(A)e_0$，其中 $\deg \pi_k \le k$、$\pi_k(0) = 1$。精确算术下至多 n 步；若只涉及 s 个不同特征值，则至多 s 步。

实际计算牢记

能量误差最优，不等于欧氏残差最小或每步下降；浮点中正交性会退化；停止时验证真实残差并结合问题尺度。