

SQP 基础：从约束线性化到 KKT-Newton

核心结论：SQP 每轮用一个二次规划产生候选方向。它同时处理目标下降与约束的一阶修复；线性化可行并不意味着真实非线性可行。

本文是四篇系列的第一篇。先理解方向如何产生，再进入第二篇的二阶结构、第三篇的 Filter 和第四篇的 Funnel。公式统一采用列向量梯度、按行排列的约束 Jacobian，以及 $g(x) \leq 0$ 的不等式约定。

1. SQP 解决什么问题？

考虑光滑非线性规划（NLP）：

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x), \\ \text{s.t.} \quad & c(x) = 0, \quad g(x) \leq 0. \end{aligned}$$

其中 $c: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$ 。负梯度只告诉我们如何降低目标，不知道哪些方向会破坏约束；可行域通常还是弯曲的。

SQP 的策略是：在当前点把约束线性化，把优化结构近似为二次模型，求出方向后再决定走多远。

$$\text{NLP} \longrightarrow \text{QP}_0 \longrightarrow \text{QP}_1 \longrightarrow \cdots, \quad x_{k+1} = x_k + \alpha_k d_k.$$

“序列”意味着在新点重建模型，不是反复求解一个固定 QP。

2. Jacobian：变量移动如何改变约束？

把各约束梯度转置后堆成行：

$$A_k = J_c(x_k) = \begin{bmatrix} \nabla c_1(x_k)^T \\ \vdots \\ \nabla c_m(x_k)^T \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

一阶展开为

$$c(x_k + d) = c_k + A_k d + O(\|d\|^2), \quad c_k = c(x_k).$$

c_k 是当前残差， $A_k d$ 是沿方向移动时约束的一阶变化。于是 $c_k + A_k d = 0$ 表示：局部线性模型预测下一点可行。

若 $c_k = 0$ 且 A_k 满行秩， $A_k d = 0$ 描述可行流形的切空间；若 $c_k \neq 0$ ，则 $A_k d = -c_k$ 是修复残差的仿射条件。

容易混淆的地方：可行点的切向条件是 $Ad = 0$ ，不可行点的 SQP 约束通常是 $Ad = -c$ 。后者不是经过原点的向量空间。

3. SQP 的 QP 子问题

记 $q_k = \nabla f(x_k)$ 、 $C_k = J_g(x_k)$ ，避免把目标梯度与不等式函数 g 混用。

$$\begin{aligned} \min_d \quad & q_k^T d + \frac{1}{2} d^T B_k d, \\ \text{s.t.} \quad & c_k + A_k d = 0, \\ & g_k + C_k d \leq 0. \end{aligned}$$

常数 f_k 不影响最小解，故省略。理论上的 exact SQP 取

$$B_k = \nabla_{xx}^2 L(x_k, \lambda_k, \mu_k), \quad L = f + \lambda^T c + \mu^T g, \quad \mu \geq 0.$$

它不是只对目标做 Taylor 展开后得到的普通二次模型： B_k 含约束曲率，第二篇会推导其来源。QP 的约束仍然是线性的。

4. 单位圆上的第一步

考虑

$$f(x, y) = (x - 2)^2 + (y - 1)^2, \quad c(x, y) = x^2 + y^2 - 1 = 0.$$

几何上是在单位圆寻找最靠近 $(2, 1)$ 的点，真实解为

$$(x_*, y_*) = \left(\frac{2}{\sqrt{5}}, \frac{1}{\sqrt{5}} \right).$$

从 $(1, 0)$ 出发，取初始乘子 $\lambda_0 = 0$ ，于是 $B_0 = 2I$ 。当前信息为

$$q_0 = \begin{bmatrix} -2 \\ -2 \end{bmatrix}, \quad A_0 = \begin{bmatrix} 2 & 0 \end{bmatrix}, \quad c_0 = 0.$$

QP 为

$$\min_{u,v} -2u - 2v + u^2 + v^2, \quad 2u = 0.$$

所以 $d_0 = (0, 1)^T$ 。它确实沿圆在 $(1, 0)$ 的切线移动，但完整步到达 $(1, 1)$ ，真实残差为 1。

对任意步长 α ，有

$$c(1, \alpha) = \alpha^2, \quad f(1, \alpha) = 2 - 2\alpha + \alpha^2.$$

因此当 $0 < \alpha < 2$ 时目标下降，约束却出现二阶误差。这不是 QP 算错，而是模型只满足一阶约束。第三篇的接受规则和 SOC 正是为这种差异服务。

5. QP 的 KKT 条件

QP 解返回 d_k 和乘子估计 $\hat{\lambda}_k, \hat{\mu}_k$ ：

$$\begin{aligned}
q_k + B_k d_k + A_k^T \hat{\lambda}_k + C_k^T \hat{\mu}_k &= 0, \\
c_k + A_k d_k &= 0, \\
g_k + C_k d_k &\leq 0, \\
\hat{\mu}_k &\geq 0, \\
\hat{\mu}_{k,j} (g_k + C_k d_k)_j &= 0.
\end{aligned}$$

等式情形可以写成 saddle-point 系统：

$$\begin{bmatrix} B_k & A_k^T \\ A_k & 0 \end{bmatrix} \begin{bmatrix} d_k \\ \hat{\lambda}_k \end{bmatrix} = - \begin{bmatrix} q_k \\ c_k \end{bmatrix}.$$

即使 $B_k \succ 0$ ，整个 KKT 块矩阵通常也是不定矩阵。若 QP 凸，KKT 在适当条件下刻画最优解；若 QP 非凸，仅满足 KKT 不能保证取到最小点。

6. SQP 为什么等价于 KKT—Newton?

只考虑等式。原 NLP 的一阶方程为

$$F(x, \lambda) = \begin{bmatrix} \nabla_x L(x, \lambda) \\ c(x) \end{bmatrix} = 0.$$

Newton 线性化得到

$$\begin{bmatrix} \nabla_{xx}^2 L_k & A_k^T \\ A_k & 0 \end{bmatrix} \begin{bmatrix} d_k \\ \Delta \lambda_k \end{bmatrix} = - \begin{bmatrix} \nabla_x L_k \\ c_k \end{bmatrix}.$$

令 $\hat{\lambda}_k = \lambda_k + \Delta \lambda_k$ ，第一行变成

$$q_k + B_k d_k + A_k^T \hat{\lambda}_k = 0.$$

这正是等式 QP 的 stationarity。因此 exact SQP 的方向可理解为对原 KKT 方程做 Newton。对不等式，局部固定活跃集后可作类似解释，还须处理活跃集改变和互补性。

核心结论：QP 乘子是更新后的乘子估计；Newton 系统里的 $\Delta \lambda$ 是增量。两者相差当前乘子，不能把两个记号混为一谈。

7. Exact 与 quasi-Newton / BFGS

Exact SQP 显式计算 Lagrangian Hessian。Quasi-Newton SQP 用梯度差构造近似，以降低二阶导成本。

定义实际接受的位移 $s_k = x_{k+1} - x_k$ ，使用同一组新乘子构造

$$y_k = \nabla_x L(x_{k+1}, \lambda_{k+1}, \mu_{k+1}) - \nabla_x L(x_k, \lambda_{k+1}, \mu_{k+1}).$$

固定乘子是为了主要捕捉变量移动带来的曲率。BFGS 为

$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{s_k^T y_k}.$$

当 $B_k \succ 0$ 且 $s_k^T y_k > 0$ 时保持正定。曲率条件失效或分母太小时，应阻尼、跳过或重置；大规模问题可以采用 L-BFGS。正定 BFGS 便于求凸 QP，但不能据此证明真实二阶条件成立。

8. 第一篇速查

组件	回答的问题
J_c	变量移动让约束一阶改变多少？
QP	如何兼顾局部目标曲率和线性约束？
QP KKT	如何联立求方向和新的乘子估计？
KKT - Newton	为什么 QP 是原一阶条件的局部解法？
Globalization	候选方向可以走多远、能否被接受？

不要误读：完整步不一定可行；QP 乘子不等于乘子增量； B_k 不只是 $\nabla^2 f$ ；KKT 矩阵不因 B_k 正定就整体正定。

下一篇用可行曲线和三次约束实例解释：为什么真正的二阶结构是 $\nabla_{xx}^2 L$ ，以及如何只在允许的方向上观察它。