

Filter-SQP：接受规则、Switching、SOC 与 Restoration

核心结论：SQP 负责产生局部候选方向；globalization 负责检验这一步是否取得可靠进展。Filter 分开管理目标值与违反度，switching 决定何时必须要求目标充分下降。

第一、二篇解释了 QP 与约束曲率。本篇把局部模型接到真实非线性问题上，最后给出接受流程。下一篇再把同一思路连接到 Funnel。

1. 方向算出来，为什么还不能直接走？

QP 中 $c_k + A_k d = 0$ ，真实残差却可能是 $O(\|d\|^2)$ ；目标的实际变化也未必符合局部模型。远离解时，完整步尤其可能走入模型失真的区域。

这里要区分两种分工：

分工	代表方法	作用
接受策略	Merit、Filter、Funnel	定义什么叫足够进展
步骤控制	Line search、Trust region	拒绝后缩步或重算局部步骤

线搜索试 $x_k + \alpha d_k$ ，逐渐缩小 α ；信赖域限制 $\|d\| \leq \Delta$ ，拒绝后通常缩小半径并重新求子问题。不能简单把“缩信赖域”写成“沿同一个方向缩 α ”。

“Global convergence”通常指从较广起点范围获得到驻点等的收敛性质，不是寻找全局最小值的保证。

2. 先统一违反度

一般约束可取

$$h(x) = \|c(x)\|_1 + \|[g(x)]_+\|_1, \quad [g]_j^+ = \max(g_j, 0).$$

$h \geq 0$ ，且 $h = 0$ 等价于原始可行。其他论文可能用二范数、平方残差或记号 θ ；比较阈值时必须先确认定义和缩放。

3. Merit function：兑换成一个标量

传统 ℓ_1 merit 为

$$\Phi_\rho(x) = f(x) + \rho h(x), \quad \rho > 0.$$

沿一个 merit 下降方向检查

$$\Phi_\rho(x_k + \alpha d) \leq \Phi_\rho(x_k) + \sigma \alpha \Phi'_\rho(x_k; d), \quad 0 < \sigma < 1.$$

h 不光滑，所以这里使用单侧方向导数；若导数不为负，就不能把右边当作充分下降要求，应先调整罚参数或方向。

等式 QP 满足 $Ad = -c$ 时， $\|c\|_1$ 的方向导数是 $-\|c\|_1$ ，所以罚项能抵消某些目标上升。在适当正则条件下，超过解处乘子相应对偶范数的参数可产生局部精确罚性质；但过大又可能过分压制目标优化。

直觉：Merit 把“目标改善”和“可行性改善”兑换成同一种货币；罚参数就是兑换率。

4. Filter：同时看两个坐标

Filter 保存历史 pair：

$$\mathcal{F} = \{(h_i, f_i)\}.$$

低 h 、低 f 都更好。候选点对每个条目至少满足一条带余量的改善条件，例如

$$\forall (h_i, f_i) \in \mathcal{F} : \quad h_t \leq (1 - \gamma_h)h_i \quad \text{或} \quad f_t \leq f_i - \gamma_f h_i,$$

其中 $0 < \gamma_h < 1$ 、 $\gamma_f > 0$ 。

逻辑是“对每个历史条目，至少改善一维”，不是“找到一个条目能改善就算通过”。如果新 pair 两坐标都不大于某旧 pair，则旧 pair 被支配，可删除。

4.1 一个可直接判断的数字例子

设 filter 只有 $(h_i, f_i) = (0.5, 10)$ ， $\gamma_h = 0.1$ 、 $\gamma_f = 0.2$ 。候选点需满足 $h_t \leq 0.45$ 或 $f_t \leq 9.9$ 。

候选 (h_t, f_t)	对这个条目的判断	原因
(0.40, 10.4)	通过	可行性改善足够，允许目标上升
(0.60, 9.8)	通过	目标改善足够，允许违反度上升
(0.48, 9.95)	不通过	两项虽然都略有改善，却达不到余量
(0.55, 10.1)	不通过	两方面都变差

这只是历史 filter 测试，最终接受还需要违反度上限、与当前点的进展检查以及可能触发的目标 Armijo 条件。

5. f-type 与 h-type：谁来证明这一步有价值？

f-type 是按目标下降验收的步骤；h-type 是未进入该分支、按 filter 或可行性规则验收的步骤。

例如 $(f, h) : (10, 0.5) \rightarrow (10.4, 0.05)$ 可以通过显著可行性改善获得接受。目标上升不自动代表失败。

但如果 $h \approx 10^{-7}$ ，算法不能长期只依赖极微小的可行性改善而忽略 stationarity。此时需要一个机制要求真正的目标进展。

严格一点的理解：某些 filter 算法里的 h-type 是“非 f-type 的可接受步”，不一定每步都严格降低 h 。类型由算法条件决定，不由名称或事后看到的单个数值决定。

6. Switching condition: 何时转向目标优化?

教学上可定义二次模型下降

$$\Delta m_k(d) = -q_k^T d - \frac{1}{2} d^T B_k d,$$

再比较 $\Delta m_k(d_k) > 0$ 且 $\Delta m_k(d_k) \geq \delta h_k^2$ 。违反度小时阈值小，算法更容易进入 f-type。

不过 B_k 含约束曲率，该量是 QP 模型下降，不是实际目标下降，也不必等于真实 f 的二阶 Taylor 预测。指数 2 更不是所有算法的统一标准。

6.1 与线搜索 Armijo 一致的一种规则

令 $D_k = -q_k^T d_k$ 。本系列完整伪代码采用以下 filter 教学规则：

$$h_k \leq h_{\min}, \quad D_k > 0, \quad \alpha D_k^{s_f} > \delta h_k^{s_h}.$$

触发时要求

$$f_t \leq f_k - \sigma \alpha D_k.$$

因为 $D_k > 0$ ，右边严格低于 f_k 。如 $f_k = 10$ 、 $D_k = 2$ 、 $\alpha = 1$ 、 $\sigma = 0.1$ ，要求 $f_t \leq 9.8$ ；9.99 虽下降，却不充分。

未触发时，仍须对当前点满足 filter 式进展，例如 $h_t \leq (1 - \gamma_h)h_k$ 或 $f_t \leq f_k - \gamma_f h_k$ 。

这类方向导数规则帮助理解 Wächter – Biegler 的 filter line-search 思路；具体阈值、指数及其他保护条件应按所读算法确定。IPOPT 的算法本体是内点法，不能因为它使用 filter 就整体称为经典 SQP。算法说明

7. Filter 更新：不是接受每个点都插入

本系列约定：h-type 接受后，把接受前的当前点 (h_k, f_k) 插入 filter，删除被它支配的条目；f-type 不插入。

这样 h-type 的折中成果成为以后必须尊重的历史边界。不同算法可能改变插入点和时机，阅读论文时应把更新规则与接受条件作为一个整体，而不是只复制一条不等式。

8. Maratos effect: 好的 Newton 步也可能被拒绝

以单条等式为例，若约束有足够光滑性，

$$c(x_k + d) = c_k + A_k d + \frac{1}{2} d^T \nabla^2 c_k d + O(\|d\|^3).$$

QP 消掉前两项，却留下二阶残差。在解附近，这种残差仍可能使一个本来适合快速局部收敛的完整步被接受策略拒绝，从而反复缩步，妨碍预期的超线性或二次收敛。

这叫 Maratos effect。不是所有完整步拒绝都属于它：方向错误、曲率不可靠或远离解也会导致拒绝。Filter 局部收敛与 SOC 分析

9. SOC：修正二阶约束误差

对完整候选 $x_t = x_k + d_k$ ，求小修正 w ：

$$A_k w \approx -c(x_t), \quad x_{\text{soc}} = x_k + d_k + w.$$

在正则、局部适用条件下， $w = O(\|d_k\|^2)$ ，所以主要修补误差而不替代原 Newton 方向。也可采用更新后的 Jacobian；有不等式时要考虑相关活跃约束并验证其余约束。

单位圆上，从 $(1, 0)$ 沿 $d = (0, t)$ 移动，残差是 t^2 。取 $w = (-t^2/2, 0)$ 后

$$c(1 - t^2/2, t) = t^4/4.$$

它展示误差从二阶降到四阶的机制；真正的 Maratos 判断还要结合目标和接受规则。SOC 候选仍需检查真实函数值，次数与大小要受限，不能未经测试自动接受。

10. Restoration：正常优化失效后先恢复可行性

当线性化约束不相容、QP 失败且无法修复，或缩到最小步长仍找不到可接受点时，进入 restoration。

例如优先求解

$$\min_x \frac{1}{2} \|c(x)\|_2^2 + \frac{1}{2} \|[g(x)]_+\|_2^2,$$

也可以采用 elastic/slack 子问题、邻近项或信赖域。暂时把重点从原目标移到违反度，但退出必须满足主算法的重返条件，不能只凭“ h 降了一点”就返回。

返回后重新估计乘子，并按规则修复或重置 Hessian 近似。如果停在 $h > 0$ 的违反度驻点，应报告恢复失败或不可行驻点；这本身不证明原问题全局无可行解。

Normal step 是正常迭代内部的一阶修复分量；restoration 是正常步骤失效后的独立阶段，两者不能互换名称。

11. 接受流程与第三篇速查

QP 方向 → 完整候选

- 是否满足违反度上限与历史 filter？
- switching 是否触发？
 - f-type：还要目标 Armijo 充分下降
 - h-type：还要对当前点取得允许的进展
- 通过：接受并按类型更新历史
- 不通过：合适时尝试 SOC，否则缩步
- 反复失败：restoration，成功后重返主算法

不要误读：filter 通过不是完整接受测试；h-type 不保证 h 每步单调下降；缩步不自动解决不相容 QP；SOC 不保证可接受；restoration 失败不等于全局不可行；switching 不是逃离局部最优的搜索机制。

下一篇用一个标量上界替代二维历史，解释 Funnel，并把四篇内容汇成完整 SQP 伪代码。