

SQP 约束优化：从局部模型到 Filter / Funnel

核心结论：SQP 用一系列二次规划（QP）产生约束优化方向；merit、filter、funnel 决定候选步如何获得接受；SOC 修补非线性约束的二阶偏差；restoration 在正常步骤失效时优先恢复可行性。

阅读说明：本文按概念关系重组教学讨论，统一采用“约束 Jacobian 按行排列”的记号。可读取的原对话包含完整 SQP 流程、filter 的步类型与 switching、KKT 残差及 funnel；更早内容未由对话接口返回。因此 Jacobian、三次约束、Hessian、null-space 等部分按本次指定主题补充推导，三次约束例子是补充教学例，非原对话逐字复原。接受条件和伪代码标明其算法版本，不能把不同论文的条件随意拼接成一个有收敛证明的实现。

目录

1. 问题、记号与 SQP 的动机
2. Jacobian 与线性化约束
3. QP 子问题、KKT 与 Newton 本质
4. 为什么使用 Lagrangian Hessian
5. Exact SQP 与 quasi-Newton / BFGS
6. 三次约束：一次完整的局部模型计算
7. Reduced Hessian、null-space 与二阶条件
8. Normal / tangential step
9. Globalization 与 merit function
10. Filter-SQP：接受区域与历史更新
11. f-type、h-type 与 switching condition
12. SOC 与 Maratos effect
13. Restoration phase
14. Funnel 方法
15. 完整教学伪代码
16. 常见误区与诊断
17. 网页发布与笔记维护
18. 一页式复习摘要

1. 问题、记号与 SQP 的动机

1.1 一般非线性规划

考虑光滑问题：

$$\min_{x \in \mathbb{R}^n} f(x), \quad c(x) = 0, \quad g(x) \leq 0.$$

其中等式约束有 m 个，不等式约束有 p 个。固定符号约定：

$$L(x, \lambda, \mu) = f(x) + \lambda^T c(x) + \mu^T g(x), \quad \mu \geq 0.$$

符号	含义与维数
$q_k = \nabla f(x_k)$	目标梯度， $n \times 1$ ；避免与不等式函数 g 混淆
$c_k, c(x_k)$	等式残差， $m \times 1$
$g_k, g(x_k)$	不等式函数值， $p \times 1$
$A_k = J_c(x_k)$	等式 Jacobian， $m \times n$
$C_k = J_g(x_k)$	不等式 Jacobian， $p \times n$
B_k	Lagrangian Hessian 或其近似， $n \times n$
d_k, α_k	SQP 方向与步长， $x_{k+1} = x_k + \alpha_k d_k$
$h(x)$	约束违反度，非负标量

本文一般问题取

$$h(x) = \|c(x)\|_1 + \|[g(x)]_+\|_1, \quad [g]_j^+ = \max(g_j, 0).$$

等式几何推导有时使用二范数；每次涉及数值阈值时应固定范数与缩放。 h 的不同定义会改变参数含义。

1.2 为什么不是直接沿负梯度走？

负梯度只知道目标在哪里下降，不知道哪些方向会破坏约束。可行域又通常是弯曲的：当前切平面上的直线移动，并不一定停留在真实可行域上。

SQP 把两类信息放进一个局部模型：用线性约束描述当前允许的移动，用二次模型描述约束优化的曲率。每次解一个 QP，再在新点重建模型。

核心结论：SQP 的“sequential”指连续重建和求解 QP；不是一次 QP 就能准确替代原非线性问题。

2. Jacobian 与线性化约束

2.1 J_c 究竟是什么？

将每个约束的梯度转置后堆成行：

$$J_c(x) = \begin{bmatrix} \nabla c_1(x)^T \\ \vdots \\ \nabla c_m(x)^T \end{bmatrix}.$$

Taylor 展开给出

$$c(x_k + d) = c_k + A_k d + O(\|d\|^2).$$

因此 QP 要求 $c_k + A_k d = 0$ ，是在要求线性模型预测下一点可行。

2.2 $A_k d = 0$ 什么时候表示切空间？

若 x_k 已经可行且 A_k 满行秩，则可行流形的切空间是

$$\mathcal{T}_k = \{d : A_k d = 0\} = \ker A_k.$$

若 $c_k \neq 0$ ，则恢复线性可行性的条件是 $A_k d = -c_k$ 。这是仿射集合，不是经过原点的切空间。

核心结论： J_c 把“变量怎么动”映射成“约束一阶怎么变”。约束不是一个标量时，不能只拿某一条约束的梯度代替整个 Jacobian。

3. QP 子问题、KKT 与 Newton 本质

3.1 标准 SQP 子问题

$$\begin{aligned} \min_d \quad & q_k^T d + \frac{1}{2} d^T B_k d, \\ \text{s.t.} \quad & c_k + A_k d = 0, \\ & g_k + C_k d \leq 0. \end{aligned}$$

常数 f_k 不影响解，故省略。QP 返回方向 d_k 和乘子 $\widehat{\lambda}_k, \widehat{\mu}_k$ 。这里的 QP 乘子是新的乘子估计，不是默认等于乘子增量。

QP 的 KKT 条件为

$$\begin{aligned} q_k + B_k d_k + A_k^T \widehat{\lambda}_k + C_k^T \widehat{\mu}_k &= 0, \\ c_k + A_k d_k &= 0, \\ g_k + C_k d_k &\leq 0, \\ \widehat{\mu}_k &\geq 0, \\ \widehat{\mu}_{k,j} (g_k + C_k d_k)_j &= 0. \end{aligned}$$

若 QP 凸，这些条件在适当正则性下刻画最优解；若 QP 非凸，满足 KKT 本身不保证它是最小点。

3.2 等式情形的 KKT 线性系统

只含等式时：

$$\begin{bmatrix} B_k & A_k^T \\ A_k & 0 \end{bmatrix} \begin{bmatrix} d_k \\ \widehat{\lambda}_k \end{bmatrix} = - \begin{bmatrix} q_k \\ c_k \end{bmatrix}.$$

注意这个块矩阵通常是不定的，即使 B_k 正定，也不能把整个 KKT 矩阵当成正定矩阵。

3.3 为什么说 SQP 是对 KKT 做 Newton?

等式 NLP 的方程是

$$F(x, \lambda) = \begin{bmatrix} \nabla_x L(x, \lambda) \\ c(x) \end{bmatrix} = 0.$$

在当前点线性化：

$$\begin{bmatrix} \nabla_{xx}^2 L_k & A_k^T \\ A_k & 0 \end{bmatrix} \begin{bmatrix} d_k \\ \Delta \lambda_k \end{bmatrix} = - \begin{bmatrix} \nabla_x L_k \\ c_k \end{bmatrix}.$$

用 $\hat{\lambda}_k = \lambda_k + \Delta \lambda_k$ ，第一行就变成 QP stationarity。因此 exact SQP 的等式步骤与 KKT-Newton 步一致。对不等式，局部固定活跃集后有类似解释，但还要处理活跃集变化和互补条件。

4. 为什么使用 Lagrangian Hessian

4.1 目标曲率之外，还有约束曲率

$$\nabla_{xx}^2 L = \nabla^2 f + \sum_{i=1}^m \lambda_i \nabla^2 c_i + \sum_{j=1}^p \mu_j \nabla^2 g_j.$$

“对 x 求二阶导”时乘子固定。它不是同时对 x, λ, μ 求 Hessian。 B_k 中的约束曲率并不意味着 QP 约束也变成二次约束；QP 约束依然线性。

4.2 沿可行曲线推导

只考虑等式，在 KKT 点 x_* 上取一条可行曲线 $x(t)$ ，满足 $x(0) = x_*$ 、 $x'(0) = v$ 。因为 $c(x(t)) = 0$ ，

$$A_* v = 0, \quad A_* x''(0) + \begin{bmatrix} v^T \nabla^2 c_1 v \\ \vdots \\ v^T \nabla^2 c_m v \end{bmatrix} = 0.$$

目标沿曲线的二阶导包含“路径转弯”这一项：

$$\left. \frac{d^2}{dt^2} f(x(t)) \right|_0 = v^T \nabla^2 f v + \nabla f^T x''(0).$$

由 stationarity $\nabla f = -A_*^T \lambda_*$ ，代入得

$$\left. \frac{d^2}{dt^2} f(x(t)) \right|_0 = v^T \left(\nabla^2 f + \sum_i \lambda_{*,i} \nabla^2 c_i \right) v = v^T \nabla_{xx}^2 L v.$$

核心结论： $\nabla^2 f$ 看直线上的目标曲率； $\nabla_{xx}^2 L$ 把沿弯曲可行域运动的效应计入。这也是 KKT-Newton 系统自然出现它的原因。

5. Exact SQP 与 quasi-Newton / BFGS

5.1 Exact SQP

每次计算 $B_k = \nabla_{xx}^2 L(x_k, \lambda_k, \mu_k)$ 。在解附近、LICQ、二阶充分条件及足够光滑等假设下，完整 Newton 步可以获得很快的局部收敛。远离解时，真实 Hessian 可能不定，QP 可能无界；需要修正曲率、信赖域或合适的非凸子问题处理。

5.2 Quasi-Newton SQP

不用显式二阶导，而利用梯度变化近似 Lagrangian Hessian。令实际接受的位移为

$$s_k = x_{k+1} - x_k,$$

在新旧两点使用相同的更新后乘子构造

$$y_k = \nabla_x L(x_{k+1}, \lambda_{k+1}, \mu_{k+1}) - \nabla_x L(x_k, \lambda_{k+1}, \mu_{k+1}).$$

这样主要捕捉 x 改变带来的曲率，而不是乘子改变本身。BFGS 更新为

$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{s_k^T y_k}.$$

当 $B_k \succ 0$ 且 $s_k^T y_k > 0$ 时保持正定。约束问题中这一曲率条件可能失败，应阻尼、跳过更新或重置。

一种 Powell 阻尼取 $0 < \eta_B < 1$ ：若 $s^T y < \eta_B s^T B s$ ，令

$$\theta = \frac{(1 - \eta_B) s^T B s}{s^T B s - s^T y}, \quad \bar{y} = \theta y + (1 - \theta) B s,$$

否则 $\bar{y} = y$ ；用 $\bar{y}$ 更新，并检查分母与数值尺度。

方法	曲率信息	主要注意点
Exact	真实 $\nabla_{xx}^2 L$	二阶导成本、负曲率、正则化
BFGS	梯度差、secant 近似	固定乘子构造 y ，阻尼与重置
Reduced BFGS	只近似切空间曲率	基底随迭代改变，需要一致的坐标处理

正定 BFGS 便于产生凸 QP，但它不能作为“真实二阶条件成立”的证据。

6. 三次约束：一次完整的局部模型计算

补充教学例：在三次曲线 $y = x^3$ 上最小化

$$f(x, y) = \frac{1}{2}[(x - 1)^2 + (y - 1)^2], \quad c(x, y) = y - x^3 = 0.$$

目标 Hessian 是 I ；约束的信息是

$$J_c(x, y) = [-3x^2 \quad 1], \quad \nabla^2 c(x, y) = \begin{bmatrix} -6x & 0 \\ 0 & 0 \end{bmatrix}.$$

因此

$$\nabla_{xx}^2 L = \begin{bmatrix} 1 - 6\lambda x & 0 \\ 0 & 1 \end{bmatrix}.$$

6.1 在一个不可行点构造 QP

取 $(x_k, y_k) = (1, 0)$ 、 $\lambda_k = -1/6$ 。则

$$c_k = -1, \quad q_k = \begin{bmatrix} 0 \\ -1 \end{bmatrix}, \quad A_k = \begin{bmatrix} -3 & 1 \end{bmatrix}, \quad B_k = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

设 $d = (u, v)$ ，QP 为

$$\min_{u,v} -v + u^2 + \frac{1}{2}v^2, \quad -1 - 3u + v = 0.$$

代入 $v = 1 + 3u$ ，目标化为 $-1/2 + (11/2)u^2$ 。故 $d_k = (0, 1)$ ，QP 乘子为 0；完整步到达 $(1, 1)$ ，这是 $f = 0$ 的全局最小点。

这次恰好沿 y 修正，非线性约束也精确满足。一般方向没有这个幸运：

$$c(x + u, y + v) = c(x, y) - 3x^2u + v - 3xu^2 - u^3.$$

QP 只消掉前三项，留下 $-3xu^2 - u^3$ 。这直接展示了 SOC 为什么有用。

6.2 切方向与约束曲率

在可行点 (a, a^3) ，可以取 null-space 基底

$$Z = \begin{bmatrix} 1 \\ 3a^2 \end{bmatrix}, \quad J_c Z = 0.$$

沿该基底的 reduced Hessian 为

$$Z^T \nabla_{xx}^2 L Z = 1 - 6\lambda a + 9a^4.$$

若只用 $\nabla^2 f = I$ ，会漏掉 $-6\lambda a$ 。基底不必归一化，但比较特征值大小时要注意基底尺度；正定性在可逆换基下不变。

7. Reduced Hessian、null-space 与二阶条件

7.1 为什么投影到 null-space?

等式正则点的允许一阶方向满足 $Av = 0$ 。若 $Z \in \mathbb{R}^{n \times (n-m)}$ 的列张成 $\ker A$ ，则 $v = Zp$ ，

$$v^T B v = p^T (Z^T B Z) p.$$

$Z^T B Z$ 是 reduced Hessian。等式问题在 LICQ 和 KKT 下，若

$$Z^T \nabla_{xx}^2 L_* Z \succ 0,$$

则满足严格局部极小的二阶充分条件。完整 Hessian 不必在整个空间正定；真正关心的是可行切方向上的曲率。

不等式问题的二阶条件应在 临界锥 (critical cone) 上检查。只有在合适的活跃集、严格互补等条件下，才可简化为活跃约束 Jacobian 的 null-space 检查。

7.2 Null-space 解 QP

先找 d_N 满足 $Ad_N = -c$ ，再写 $d = d_N + Zp$ 。于是

$$(Z^T B Z)p = -Z^T(q + Bd_N).$$

这把约束 QP 的自由度压缩到 $n - m$ 维。若 A 满行秩且 $Z^T B Z \succ 0$ ，等式 QP 有唯一最小解，KKT 矩阵也非奇异。

8. Normal / tangential step

8.1 两个职责

写成 $d = d_N + d_T$ ：normal step 主要降低线性化约束残差，tangential step 主要利用余下自由度改善目标。等式满行秩时，最小范数 normal step 为

$$d_N = -A^T(AA^T)^{-1}c.$$

实际计算用 QR、SVD 或线性求解，避免显式形成逆矩阵。Tangential step 满足 $Ad_T = 0$ ，并求解

$$\min_{d_T} (q + Bd_N)^T d_T + \frac{1}{2} d_T^T B d_T, \quad Ad_T = 0.$$

8.2 远离可行域时

在信赖域方法中，normal step 常改为

$$\min_{\|d_N\| \leq \Delta_N} \frac{1}{2} \|c + Ad_N\|_2^2.$$

这允许只做部分可行性修复，再用切向步完成优化。Tangential step 还须遵守总步长预算。对不等式，需结合活跃集或 slack 变量；不能把所有不等式都当作必须满足等号的约束。

核心结论：normal / tangential 是一种几何和算法分工，不是所有 SQP 实现都必须显式求两个独立子问题。

9. Globalization 与 merit function

9.1 为什么不能一直走完整步？

局部模型只在附近准确。远离解时，完整步可能使非线性约束恶化、目标上升或进入模型失真的区域。Globalization 用线搜索或信赖域控制这一风险。

这里“global convergence”通常指从较广的初始点范围建立到驻点等的收敛性质，不是保证找到全局最优解。

9.2 Merit：把两个目标合成一个标量

常用 ℓ_1 精确罚函数：

$$\phi_\rho(x) = f(x) + \rho h(x), \quad \rho > 0.$$

沿方向要求 Armijo：

$$\phi_\rho(x_k + \alpha d_k) \leq \phi_\rho(x_k) + \sigma \alpha \phi'_\rho(x_k; d_k), \quad 0 < \sigma < 1.$$

因为 h 不光滑，这里是单侧方向导数。只有方向导数为负时，该式才要求下降；否则需调整罚参数或修复方向。

等式 QP 满足 $Ad = -c$ 时， $\|c\|_1$ 的方向导数是 $-\|c\|_1$ 。在适当条件下，罚参数大于解处乘子的相应对偶范数，可体现局部“精确罚”性质；但参数过大容易让优化被可行性项压住。

10. Filter-SQP：接受区域与历史更新

10.1 Filter 保存什么？

保存若干历史 pair： $\mathcal{F} = \{(h_i, f_i)\}$ 。低 h 、低 f 都更好。候选点必须对每一个 filter 条目至少在一个维度取得带余量的改善，例如

$$\forall (h_i, f_i) \in \mathcal{F}: \quad h_t \leq (1 - \gamma_h)h_i \quad \text{或} \quad f_t \leq f_i - \gamma_f h_i.$$

其中 $0 < \gamma_h < 1$ 、 $\gamma_f > 0$ 。这里的“或”在每个条目内部成立；不是找到任意一个条目可以改善就通过。

若新 pair 两个坐标都不比某条目更大，则新 pair 支配该条目，后者可删除。加入历史点使算法不容易反复回到已经取得过的较差折中。

10.2 只有 filter 检查够吗？

不够。还要与当前点比较、设置违反度上限，并用 switching 和目标充分下降条件防止接近可行域时只靠微小的约束改善停滞。

核心结论：filter 允许目标暂时上升，也允许违反度暂时上升，但两者不是任意上升。它管理的是经过余量保护的历史接受区域。Filter line-search 的原始分析

11. f-type、h-type 与 switching condition

11.1 步类型是验收职责

- f-type：方向预测了值得追求的目标下降，必须验证真实目标充分下降。
- h-type：没有进入上述目标下降分支，靠 filter 或可行性规则取得接受，目标可以上升。

在某些 filter 算法中，h-type 的逻辑是“非 f-type 的 filter 接受步”，不一定严格等价于 $h_{k+1} < h_k$ 。名称是帮助理解职责，最终以接受条件为准。

例如 $(f, h) : (10, 0.5) \rightarrow (10.4, 0.05)$ 可作为可行性进展；若 $h \approx 10^{-7}$ ，只改善一点 h 而完全不改善最优性，就不能长期满足算法的收敛需求。

11.2 简化的模型下降 switching

定义 SQP 局部模型下降：

$$\Delta m_k(d) = -q_k^T d - \frac{1}{2} d^T B_k d.$$

它是局部 QP 模型的预测量；因 B_k 含约束曲率，不能把它当作真实 f 的精确 Taylor 下降。一种教学规则是

$$\Delta m_k(d_k) > 0, \quad \Delta m_k(d_k) \geq \delta h_k^2.$$

h 小时阈值小，算法更容易要求目标下降。指数 2 和参数并非所有 filter / funnel 方法的统一标准。

11.3 本笔记伪代码采用的线搜索规则

为让方向导数和 Armijo 一致，定义 $D_k = -q_k^T d_k$ 。Filter 分支采用一种 Wächter – Biegler 风格的规则：

$$h_k \leq h_{\min}, \quad D_k > 0, \quad \alpha D_k^{s_f} > \delta h_k^{s_h}.$$

触发时用

$$f(x_k + \alpha d_k) \leq f_k - \sigma \alpha D_k.$$

例如 $f_k = 10$ 、 $D_k = 2$ 、 $\sigma = 0.1$ 、 $\alpha = 1$ ，则要求 $f_t \leq 9.8$ ；9.99 虽下降，却不够。

未触发时采用与当前点的 filter 式进展检查。具体论文还可能对指数、阈值和 filter 更新施加额外要求。

IPOPT 是采用 filter 的内点算法，不能把它整体称为经典 SQP；这里借用其接受逻辑帮助阅读。[Wächter – Biegler 算法说明](#)

11.4 历史更新的一个明确约定

本笔记在 h-type 接受后，把接受前当前点 (h_k, f_k) 插入 filter，删除被该 pair 支配的旧条目；f-type 不插入。不同论文可能采用移动后的点或其他更新时机，应连同接受规则整体阅读。

12. SOC 与 Maratos effect

12.1 线性可行不等于非线性可行

若 $c_k + Ad = 0$ ，仍可能有

$$c(x_k + d) = O(\|d\|^2).$$

Maratos effect 指解附近本来适合快速收敛的完整 SQP 步，因为这些二阶约束误差而被 merit / 接受规则拒绝；反复缩步会妨碍预期的快速局部收敛。

12.2 Second-order correction

在完整步 $x_t = x_k + d$ 被约束误差阻挡时，求一个小修正 w ：

$$A_k w \approx -c(x_t), \quad x_{\text{soc}} = x_k + d + w.$$

也可用更新后的 Jacobian；在正则情形下 $w = O(\|d\|^2)$ 。修正后仍须重新检查真实函数值和约束值。处理不等式时主要修正有关活跃约束，并验证所有不等式。

12.3 单位圆上的直观例子

在 $(1, 0)$ 、约束 $x^2 + y^2 - 1 = 0$ 上，切向步 $d = (0, t)$ 满足 $Ad = 0$ ，却产生残差 t^2 。取 $w = (-t^2/2, 0)$ ，有

$$c(1 - t^2/2, t) = t^4/4.$$

一个二阶小修正将违反度从二阶降为四阶。实际最优化中的 Maratos effect 还涉及目标和接受测试；此例只展示约束修正机制。

核心结论：SOC 是对一个已有好方向的小修补，不是另一次完整优化；它不保证一定可接受，也不是每次回溯都必须调用。

13. Restoration phase

13.1 什么时候进入？

线性化约束不相容、QP 求解失败且修正无效，或回溯到最小步长仍无法接受时，可以进入 restoration。QP 失败也可能来自数值病态、无界或求解器问题，应先辨别原因。

等式违反度子问题常取

$$\min_x v(x) = \frac{1}{2} \|c(x)\|_2^2,$$

一般约束可加入 $\frac{1}{2} \| [g(x)]_+ \|_2^2$ ，也可用 slack / elastic 变量、邻近项或信赖域。

13.2 退出并不是“ h 降了就回去”

必须满足主算法的重返条件：例如获得足够可行性进展，且新点能通过 filter 或进入 funnel；还要能够重新构造可用的主问题步骤。Restoration 后乘子应重新估计，Hessian 近似应按规则重置或修复。

若 restoration 停在 $h > 0$ 的驻点，只能报告恢复失败或不可行驻点等状态，不能仅凭它断言原问题无可行解。

核心结论：restoration 是优先恢复可行性的独立阶段；normal step 是正常步骤内部的组成部分，二者不是同义词。

14. Funnel 方法

14.1 从二维历史到一个违反度上界

维护 funnel width τ_k ，并保证

$$h(x_k) \leq \tau_k, \quad \tau_{k+1} \leq \tau_k.$$

候选点首先必须处于漏斗内。Funnel 边界只是资格条件，还要检查目标下降或可行性进展。下面给出与原讨论相近的教学规则；完整算法的收敛依赖 switching、目标有界和恢复机制等额外条件，单调 τ 本身不保证 $h \rightarrow 0$ 。统一 funnel restoration SQP 框架

14.2 f-type 与 h-type

模型版本可比较 Δm_k 与 δh_k^2 ，要求模型下降为正。若触发 f-type 且

$$h_t \leq \tau_k, \quad f_k - f_t \geq \sigma \Delta m_k,$$

则接受并令 $\tau_{k+1} = \tau_k$ 。有些方法用线性预测下降而非二次模型，必须与实际定义一致。

若未触发，则 h-type 的一种接受条件和更新为

$$h_t \leq \beta \tau_k, \quad \tau_{k+1} = (1 - \kappa)h_t + \kappa \tau_k, \quad 0 < \beta, \kappa < 1.$$

于是 $h_t \leq \tau_{k+1} < \tau_k$ （当 $\tau_k > 0$ ）。它保证收窄上界，但不必保证 $h_t < h_k$ 。

14.3 数值例子

设 $\tau_0 = 1$ 、 $h_0 = 0.7$ ，h-type 候选 $h_t = 0.4$ ， $\beta = 0.8$ 、 $\kappa = 0.5$ 。接受后 $\tau_1 = 0.7$ 。

下一次 f-type 将 $h : 0.4 \rightarrow 0.5$ ，仍在 $\tau_1 = 0.7$ 内；若目标充分下降，仍可接受，宽度保持 0.7。

核心结论：funnel width 单调不增，约束违反度不必每一步单调不增。某些框架可把 funnel 解释成特殊 filter，但一般 funnel 算法不能不加条件地等同于“只存一个历史点的 filter”。

14.4 三种 globalization 的比较

方法	保存的状态	核心接受依据	主要维护任务
Merit	罚参数 ρ	$f + \rho h$ 充分下降	平衡尺度、更新罚参数
Filter	若干 (h_i, f_i)	对历史条目改善至少一维，并配合 switching	插入、支配删除、历史测试
Funnel	上界 τ_k	留在边界内，配合目标下降或收窄条件	维护和收紧违反度上界

三者都可以配合 SOC 和 restoration。它们管理迭代的进展，不负责在不同非凸吸引域之间搜索全局最优解。

15. 完整教学伪代码

15.1 范围与约定

以下是线搜索 SQP 的模块化教学框架，覆盖成功、回溯、SOC、恢复与终止路径。它不是某个求解器的逐行复现，也不是直接运行的生产实现。Filter 使用第 11 节的方向导数规则；funnel 为保持线搜索一致，采用 αD_k 的线性预测版本。第 14 节的二次模型版本是另一选择，不与这里混用。

参数满足 $0 < \sigma, r, \beta, \kappa, \gamma_h < 1, \delta, \gamma_f > 0$ 。停止使用经过合理缩放的完整 NLP KKT 残差，包含 stationarity、等式、不等式违反度、乘子非负性和互补性。

```

输入  $x_0, \lambda_0, \mu_0 \geq 0, B_0$ , 容差, 迭代/时间上限
选择  $\text{mode} \in \{\text{MERIT}, \text{FILTER}, \text{FUNNEL}\}$ 
初始化罚参数  $\rho$ ; filter  $F = \text{空集}$ ;  $\tau_0 \geq h(x_0)$ 

for  $k = 0, 1, \dots$ :
    计算  $f, q=\nabla f, c, g, A=Jc, C=Jg$ 
    若完整、缩放后的 NLP KKT 残差满足容差:
        返回“一阶 KKT 收敛”及残差 (不宣称全局最优)
    若迭代/时间达到上限: 返回“达到上限”

    exact:  $B = \nabla^2 x x L(x_k, \lambda_k, \mu_k)$ 
    quasi-Newton: 使用已有  $B_k$ 
    必要时按所用 QP 策略修正曲率/正则化

    解 QP:  $\min q^T d + 0.5 d^T B d$ 
        s.t.  $c + A d = 0, g + C d \leq 0$ 
    得到  $d, \lambda_{\text{hat}}, \mu_{\text{hat}}$ 
    若 QP 无有效解: 转 RESTORE
    若  $d$  很小但 KKT 残差仍大: 诊断/修复; 失败则 RESTORE

    若 MERIT: 更新  $\rho$ , 确保  $\phi \rho'(x_k; d) < 0$ 
        若无法取得下降方向: RESTORE
     $D = -q^T d; \alpha = 1; \text{accepted} = \text{false}$ 

    while  $\alpha \geq \alpha_{\min}$ :
         $x_t = x_k + \alpha d$ ; 计算  $f_t, h_t$ 
         $(\text{ok}, \text{type}) = \text{ACCEPT}(x_t, \alpha, D, \text{mode})$ 
        若 ok:  $\text{accepted} = \text{true}; \text{break}$ 

        若  $\alpha=1$  且拒绝主要来自非线性约束偏差:
            尝试有限次 SOC, 求小修正  $w$ 
             $x_{\text{soc}} = x_k + d + w$ 
            若  $w$  足够小且  $x_{\text{soc}}$  通过同一真实接受规则:
                 $x_t = x_{\text{soc}}$ ; 记录 SOC;  $\text{accepted} = \text{true}; \text{break}$ 
         $\alpha = r \alpha$ 

    若未 accepted: 转 RESTORE

    若 FILTER 且  $\text{type}=h$ :
        向  $F$  插入旧点  $(h_k, f_k)$ , 删除被它支配的条目
    若 FUNNEL 且  $\text{type}=h$ :  $\tau_{\text{new}} = (1-\kappa)h_t + \kappa\tau_k$ 
    若 FUNNEL 且  $\text{type}=f$ :  $\tau_{\text{new}} = \tau_k$ 

     $x_{\text{new}} = x_t$ 
    选择乘子更新策略: 如用  $\alpha_{\text{dual}} \in (0, 1]$ 
     $\lambda_{\text{new}} = \lambda_k + \alpha_{\text{dual}}(\lambda_{\text{hat}} - \lambda_k)$ 
     $\mu_{\text{new}} = \mu_k + \alpha_{\text{dual}}(\mu_{\text{hat}} - \mu_k)$ 
    或在新点重新估计乘子; 保持  $\mu_{\text{new}} \geq 0$ 
    若 quasi-Newton:
         $s = x_{\text{new}} - x_k$  (含 SOC 的实际位移)
         $y = \nabla_x L(x_{\text{new}}, \lambda_{\text{new}}, \mu_{\text{new}}) - \nabla_x L(x_k, \lambda_{\text{new}}, \mu_{\text{new}})$ 
        用阻尼 BFGS 更新; 异常时跳过或重置

```

更新状态; continue

RESTORE:

解局部违反度最小化/elastic 子问题

寻找具有足够违反度进展且满足主算法重返条件的 x_R

若成功:

按该算法规则维护 F 或 τ , 使新点满足不变量

$x_{\text{new}} = x_R$; 重新估计乘子; 重置/修复 B ; continue

否则: 返回“恢复失败/不可行驻点/数值失败”等诊断

15.2 接受模块

ACCEPT($x_t, \alpha, D, \text{mode}$):

MERIT:

返回 $\varphi(x_t) \leq \varphi(x_k) + \alpha \varphi'(x_k; d)$

FILTER:

若 h_t 超过允许上限: 拒绝

若对 F 任一条目, 两条改善不等式都不满足: 拒绝

switch = ($h_k \leq h_{\min}$ 且 $D > 0$ 且 $\alpha D^{\text{sf}} > \delta h_k^{\text{sh}}$)

若 switch: 返回 ($f_t \leq f_k - \alpha D, f$)

否则: 返回

($h_t \leq (1 - \gamma) h_k$ 或 $f_t \leq f_k - \gamma f(h_k, h)$)

FUNNEL (线性预测的教学版本):

若 $h_t > \tau_k$: 拒绝

switch = ($D > 0$ 且 $\alpha D \geq \delta h_k^2$)

若 switch: 返回 ($f_t \leq f_k - \alpha D, f$)

否则: 返回 ($h_t \leq \beta \tau_k, h$)

SOC 候选采用其基步的预测量并限制修正大小; 有收敛证明的实现还需明确 SOC 次数、大小界和专用验收细节。Restoration 的 filter 插入及 funnel 收窄必须与所选择的论文一致, 不能用“随意清空历史或放宽边界”替代。

16. 常见误区与诊断

16.1 KKT 残差很小, 目标为何仍然很高?

取单位圆上的问题 $\min x$, 约束 $x^2 + y^2 = 1$ 。

在 $(1, 0)$, 取 $\lambda = -1/2$, 则 $c = 0, \nabla_x L = 0$, 但该点是最大点; $Z = (0, 1)^T$, 有 $Z^T \nabla^2 L Z = -1$ 。

在 $(-1, 0)$, 取 $\lambda = 1/2$, 则 reduced Hessian 为 1, 目标才取得最小值 -1 。

因此残差小首先意味着近似一阶驻定和可行。病态或退化时, 残差小甚至不一定意味着变量在距离上接近某个精确 KKT 点。

16.2 复习时最容易混淆的判断

误区	正确理解
L residual 就是 $ L $	stationarity residual 是 $\ \nabla_x L\ $
只检查 c 和 ∇L 足够	有不等式还要检查违反度、对偶可行与互补性
$\nabla f = 0$ 才能最优	约束最优时梯度可由约束梯度与乘子抵消
B 一定是 $\nabla^2 f$	它近似 $\nabla_{xx}^2 L$ ，含约束曲率
$B \succ 0$ 才能是约束极小点	等式问题主要看切空间曲率；不等式看临界锥
QP 可行则新点一定可行	只保证线性化约束；仍有高阶误差
h-type 每步必须降低 h	依具体 filter / funnel 接受规则，不能只凭名称判断
在 funnel 内就接受	还要满足相应充分下降条件
τ 单调即可推出 $h \rightarrow 0$	还依赖 switching、界限和恢复等机制
Switching 能逃离局部最优	它管理步的验收，不是全局搜索
Restoration 失败证明问题不可行	可能停在局部违反度驻点或数值失败

16.3 一个实用的诊断次序

先检查导数和尺度，再检查完整 KKT 残差；若残差小但解不理想，检查真实 reduced Hessian / 临界锥曲率，并区分局部解和全局解。若残差不小但步长不断缩小，查看 QP 状态、预测下降、实际下降、filter / funnel 拒绝原因以及 SOC、restoration 是否正常工作。

例如 $f(x) = 10^{-12}x^2$ 在 $x = 10^5$ 时梯度仅为 2×10^{-7} ，绝对容差 10^{-6} 可能误判 stationarity。应结合缩放、相对尺度和问题物理含义解释数值。

17. 网页发布与笔记维护

把 Markdown 作为可编辑主版本，PDF 作为打印和固定版本。此文件使用 ... 行内数学与

...

独立数学；网页需启用兼容的 KaTeX 或 MathJax 渲染。普通 Markdown 渲染器不一定支持数学。

建议每个知识点保持三层：它解决什么问题 → 关键公式与算法位置 → 自己曾卡住的“为什么”。例如“为什么用 $\nabla^2 L$ ”放在 Hessian 推导之后，比按聊天顺序保存零散问答更容易复习。

发布前检查公式、矩阵换行、表格在手机上的宽度和代码块换行。保留术语、符号约定和版本说明；遇到新论文时，把该论文的 h 定义、预测下降和 switching 单独记录，避免偷换符号。

18. 一页式复习摘要

问题与局部方向

$$\min f(x), \quad c = 0, \quad g \leq 0; \quad L = f + \lambda^T c + \mu^T g, \quad \mu \geq 0.$$

$$\min_d q^T d + \frac{1}{2} d^T B d, \quad c + A d = 0, \quad g + C d \leq 0.$$

$A = J_c$ 按行堆约束梯度; $B \approx \nabla_{xx}^2 L$ 包含约束曲率。Exact 使用真实二阶导; BFGS 用同一乘子下的 Lagrangian 梯度差并检查曲率。

几何与二阶信息

$Ad_N = -c$ 修复线性可行性; $d_T = Zp$, $AZ = 0$ 使用切自由度。Reduced Hessian 为 $Z^T B Z$; 真实二阶充分条件在等式切空间、不等式临界锥上判断。

三种验收思路

Merit: $f + \rho h$ 充分下降。Filter: 对每个历史 pair 至少改善一维, 近可行时加 switching / Armijo。

Funnel: $h_t \leq \tau$, f-type 要目标下降, h-type 收窄上界。

f / h 与两个补救模块

f-type 用正的预测目标下降触发并验真实下降; h-type 按相应可行性 / filter 规则验收。Switching 的指数和预测量依论文变化。SOC 修二阶约束误差; restoration 在正常步骤失效后优先降低违反度。

算法骨架与停止含义

求导 $\rightarrow$ 构造 / 更新 $B \rightarrow$ 解 QP $\rightarrow$ 验收 / 回溯 $\rightarrow$ SOC 或 restoration $\rightarrow$ 更新点与乘子 $\rightarrow$ BFGS $\rightarrow$ 检查完整 KKT。

KKT 包括 stationarity、原始可行、对偶可行、互补性。小残差说明近似一阶条件; 真实正的切向曲率支持局部极小; 非凸问题仍不保证全局最优。 f 和 h 都不必逐步单调。

参考与进一步阅读

- 原教学对话：《不会嫌弃你》，本笔记按指定主题重组并补充；不保留聊天中的临时引用占位符。
- Wächter – Biegler: Filter line-search 的局部收敛分析：用于核对 filter 与 SOC 的关系。
- Wächter – Biegler: 内点 filter line-search 实现：用于理解 switching、restoration、SOC；算法本体为内点法。
- Kiessling、Leyffer、Vanaret: A Unified Funnel Restoration SQP Algorithm：用于进一步核对 funnel 边界与恢复框架。本文的具体接受模块仍标为教学版本。